Proyecto Integrador I - GRIA - USC

Análisis ergonómico en el puesto de trabajo

Mediante visión artificial

Grupo:	DTL2_GT12
Curso:	2025-2026
Entrega:	AVP3 - Informe final de resultados
Versión:	2.0
Repositorio:	https://github.com/Veleiroo/Proyecto-Integrador-I

Este informe sintetiza los resultados obtenidos, las desviaciones respecto al plan inicial, los problemas encontrados, las líneas de mejora y las conclusiones de negocio y tecnología. Las evidencias proceden de los benchmarks de modelos, las corridas completas del pipeline y la aplicación local desarrollada en el repositorio público del proyecto: https://github.com/Veleiroo/Proyecto-Integrador-I [1].

Índice

Resumen ejecutivo **2**

1. Resultados obtenidos y objetivos no alcanzados **2**

1.1. Resultados alcanzados 2

1.2. Arquitectura final entregada 4

1.3. Privacidad, seguridad y validación funcional 5

1.4. Comprobación final del modelo lateral 5

1.5. Objetivos no alcanzados 5

2. Desviaciones respecto al plan inicial **6**

3. Dificultades durante la ejecución **6**

4. Acciones de mejora y evolución futura **7**

5. Conclusiones **7**

5.1. Conclusiones de negocio 7

5.2. Conclusiones tecnológicas 8

Resumen ejecutivo

El proyecto ha alcanzado una prueba de concepto funcional para analizar posturas de trabajo sedentario con visión por computador. El resultado final combina un pipeline científico modular, una aplicación web local-first y un sistema de reglas que transforma keypoints corporales en métricas ergonómicas interpretables.

La principal decisión técnica ha sido especializar el modelo por vista: MediaPipe Pose se mantiene como opción frontal por su cobertura estable de cabeza y hombros, mientras que YOLO Pose se usa para la vista lateral por su mejor comportamiento en perfil. La última comprobación de modelos laterales recomienda YOLO11s frente a YOLOv8s y YOLO26 para el estado actual del proyecto, al mejorar ligeramente la validez del tronco sin perder cobertura.

Desde el punto de vista de producto, el sistema se orienta a prevención y autocuidado, no a supervisión laboral. Esta decisión reduce riesgos de privacidad, encaja con el uso de webcam local y facilita un despliegue inicial sin hardware adicional. La solución no sustituye una evaluación ergonómica profesional, pero sí valida una base técnica para alertas preventivas, histórico individual y calibración posterior con datos reales.

1 Resultados obtenidos y objetivos no alcanzados

1.1 Resultados alcanzados

Benchmark y selección de modelos. Se compararon MediaPipe Pose, YOLO Pose y MoveNet sobre los datasets disponibles. En la vista frontal, MediaPipe Pose obtuvo la mejor cobertura útil para el tren superior: `upper_body_ready_pct` de 84,2 %, frente al 41,4 % de MoveNet y el 9,2 % de YOLO Pose. En la vista lateral, YOLO Pose fue claramente superior, con `side_view_ready_pct` de 98,2 % y `full_ergonomic_ready_pct` de 96,5 %.

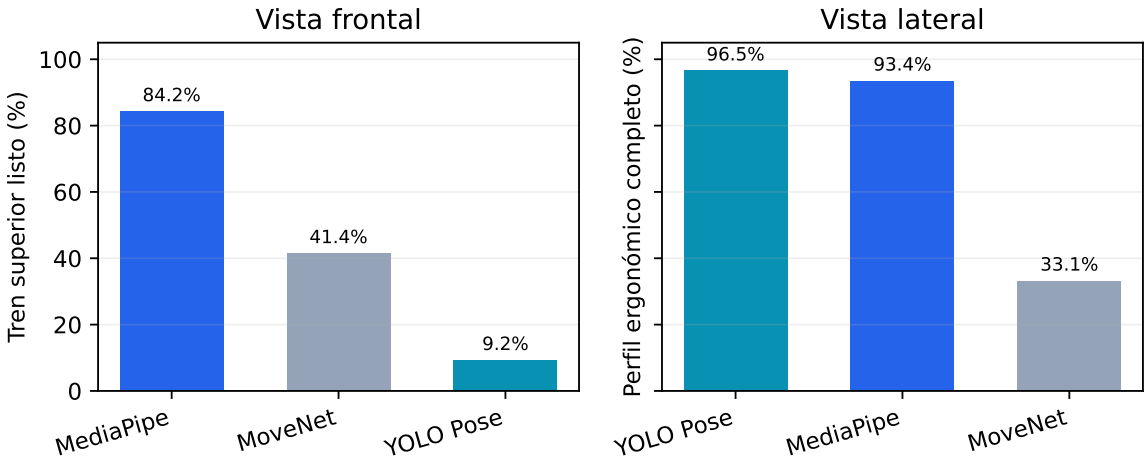

Figura 1: Métrica de selección por vista: tren superior en frontal y perfil completo en lateral. *Fuente: benchmarks de pose del repositorio.*

Pipeline frontal. El módulo frontal calcula métricas de cabeza, cuello, hombros y tronco a partir de keypoints 2D. Las reglas principales son:

- inclinación de hombros y diferencia relativa de altura;
- desplazamiento lateral de cabeza e inclinación cervical;
- inclinación lateral del tronco cuando las caderas son visibles;
- ángulos de codo como métrica informativa, sin elevar por sí solos el diagnóstico.

En la corrida completa frontal se procesaron 4.666 imágenes. El resultado global fue 57,8 % `risk`, 25,3 % `improvable`, 16,8 % `adequate` y 0,15 % `insufficient_data`. Este comportamiento muestra que el pipeline es capaz de emitir diagnósticos con baja pérdida de señal, pero también confirma que las etiquetas visuales de datasets públicos no equivalen a una verdad ergonómica estricta.

Pipeline lateral. La extensión lateral permite medir variables que la webcam frontal no resuelve bien: adelantamiento de cabeza, inclinación cervical hacia delante, inclinación frontal del tronco y desplazamiento hombro-cadera. Sobre 655 imágenes laterales, la distribución global fue 50,2 % `risk`, 27,3 % `adequate`, 22,1 % `improvable` y 0,3 % `insufficient_data`. En el grupo etiquetado como *Bad*, el 62,1 % terminó en riesgo; en *Good*, el riesgo bajó al 28,9 % y el estado adecuado subió al 43,0 %.

Sistema de reglas e interpretación visual. El valor del proyecto no está solo en detectar puntos corporales, sino en convertirlos en criterios explicables. Cada captura sigue el mismo flujo: se detectan keypoints, se filtran por confianza, se construyen segmentos anatómicos, se calculan métricas geométricas y se emite un estado con feedback textual. La Figura 2 muestra dos salidas reales generadas por el modo de depuración: los puntos amarillos son keypoints válidos y las líneas coloreadas representan reglas como eje cervical, línea de hombros, tronco y cadena brazo-hombro.

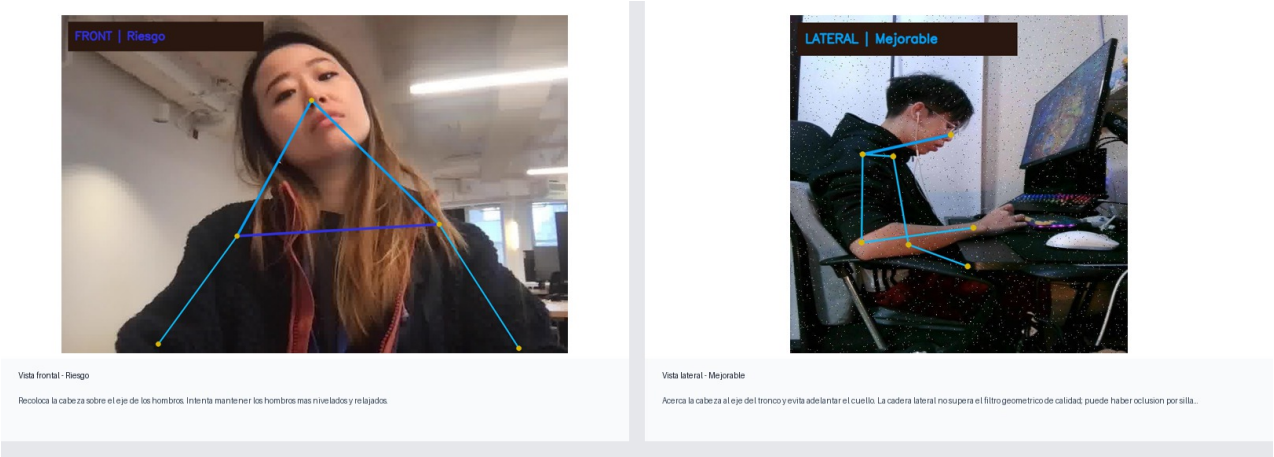

Figura 2: Ejemplos reales del overlay de reglas usado para depuración técnica.

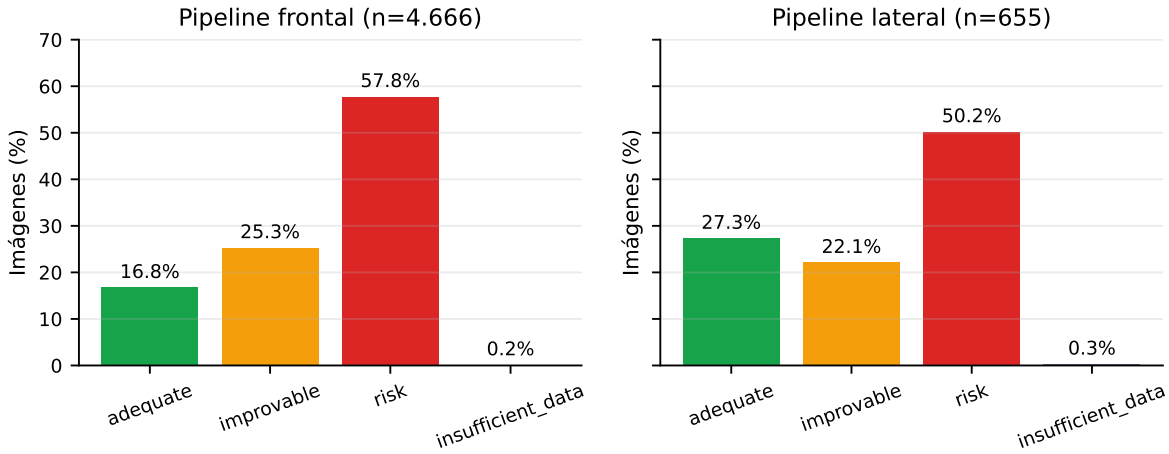

Figura 3: Distribución de estados en las corridas completas frontal y lateral. *Fuente: corridas completas del pipeline.*

Aplicación local-first. Se construyó una aplicación completa con backend FastAPI, frontend React/Vite, base de datos SQLite local cifrada, autenticación, historial, estadísticas y panel de depuración visual. El flujo de datos evita subir imágenes a la nube: los ficheros se procesan de forma temporal y se eliminan tras el análisis, salvo en la vista técnica de depuración.

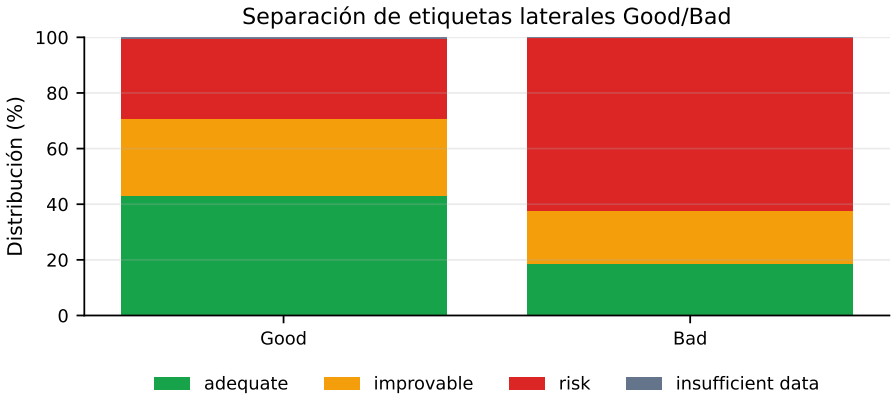

Figura 4: Separación de las clases laterales *Good/Bad* tras aplicar reglas ergonómicas. *Fuente: resumen por grupo del dataset lateral.*

Empaquetado de ejecución. El proyecto incorpora scripts de arranque para Windows, Linux y macOS. Estos preparan un entorno virtual, instalan dependencias, descargan los modelos y sirven la web compilada desde FastAPI en un único servidor local. Esto no convierte el proyecto en una aplicación nativa cerrada, pero sí lo deja distribuible como carpeta ejecutable reproducible.

1.2 Arquitectura final entregada

El resultado no se limita a un conjunto de notebooks. La implementación final separa el pipeline científico, la capa de aplicación y la interfaz de usuario, lo que permite cambiar reglas, modelos o vistas sin rehacer el producto completo.

Bloque	**Módulos principales**	**Responsabilidad**
Inferencia de pose	`pose_inference.py`, `yolo_pose_inference.py`	Carga de MediaPipe y YOLO, normalización de keypoints y selección del dispositivo de ejecución.
Reglas ergonómicas	`posture_rules.py`, `lateral_rules.py`	Conversión de coordenadas en métricas geométricas y estados `adequate`, `improvable`, `risk` o `insufficient_data`.
Ejecución experimental	`benchmark.py`, `long_run.py`, `audit.py`, notebooks	Comparación de modelos, corridas completas, auditoría de resultados y calibración inicial.
Aplicación local	`api.py`, `app_service.py`, `app_storage.py`, `app_security.py`	API, combinación frontal-lateral, almacenamiento cifrado, autenticación e historial.
Interfaz y distribución	`apps/web/`, `scripts/`, `launchers/`	Web React/Vite, paneles de cámara/estadísticas/historial/debug y lanzadores multiplataforma.

Tabla 1: Componentes principales de la solución final.

La API expone endpoints de autenticación, análisis frontal, análisis lateral, análisis combinado, historial, resumen estadístico y depuración visual. En producción local sirve también la web compilada desde FastAPI, por lo que el usuario final accede a la aplicación desde un único servidor local. La configuración permite cambiar el dispositivo YOLO y el path de pesos mediante variables de entorno, manteniendo por defecto `yolo11s-pose.pt`.

La interfaz final cubre cinco flujos de usuario: captura desde cámara, estadísticas agregadas, historial local, información de privacidad y depuración visual para perfil técnico. Esta última vista fue especialmente útil para validar la coherencia entre keypoints, líneas de regla y diagnóstico emitido, ya

que permite inspeccionar visualmente por qué una captura se clasifica como adecuada, mejorable, de riesgo o insuficiente.

Evidencia	Artefacto	Resultado aprovechado en el informe
Benchmark frontal	Notebook de benchmark de pose	Selección de MediaPipe por cobertura útil del tren superior.
Benchmark lateral	Resumen lateral de pose	Selección de YOLO Pose para perfil por cobertura ergonómica completa del 96,5 %.
Long run frontal	Pipeline ergonómico completo	Corrida completa de 4.666 imágenes y distribución global de estados.
Pipeline lateral	Pipeline lateral YOLO	Corrida lateral de 655 imágenes y separación Good/Bad.
Calibración	Calibración lateral Multi-Posture	Ajuste conceptual de reglas de tronco con datos 3D expertos.
Cierre de producto	API, web y Playwright	Verificación de endpoints, interfaz, modo técnico y distribución local.

Tabla 2: Trazabilidad entre notebooks, resultados y decisiones del producto.

1.3 Privacidad, seguridad y validación funcional

El diseño local-first responde a una decisión de producto y de ingeniería. Las imágenes subidas al análisis normal se guardan como ficheros temporales y se eliminan al finalizar. Los resultados persistentes se almacenan en SQLite con payload cifrado, las sesiones se guardan mediante hashes de token y los usuarios semilla solo se crean si no existen, evitando sobrescribir contraseñas tras un reinicio.

La aplicación final se verificó con tres tipos de comprobaciones: compilación Python de los módulos y scripts, typecheck y build del frontend, y suite Playwright sobre la web servida desde FastAPI. La prueba final validó 14 escenarios, incluyendo modo claro/oscuro, navegación por roles, cámara lateral, análisis combinado y presentación de métricas en castellano.

1.4 Comprobación final del modelo lateral

Tras el cierre funcional se evaluaron variantes YOLO más actuales. El resultado no justificó sustituir el frontal por YOLO: aunque algunos modelos fueron más rápidos en GPU, no aportaron mejor disponibilidad del tronco frontal debido a la oclusión habitual de caderas por mesa y silla. En lateral, YOLO11s fue la alternativa más equilibrada: 100 % de detección, 86,7 % de torso lateral válido y 11,1 ms de mediana.

1.5 Objetivos no alcanzados

- **Evaluación completa del cuerpo desde una única webcam.** No se alcanzó porque muñecas, caderas, rodillas y pies suelen quedar fuera del encuadre o tapados por el escritorio. Forzar estas reglas producía falsos positivos y estados insuficientes.
- **Uso directo de etiquetas *Good/Bad* como verdad ergonómica.** Las etiquetas visuales son útiles para agrupar imágenes, pero no son equivalentes a una evaluación ROSA ni a criterios posturales normativos.
- **Aplicación nativa cerrada.** Se descartó por alcance y coste. En su lugar se entregó una WebApp local-first con lanzadores multiplataforma, más adecuada para una prueba de concepto privada y reproducible.
- **Validación clínica o corporativa con usuarios reales.** El proyecto valida la viabilidad técnica, pero no mide todavía impacto en reducción de lesiones, adherencia de usuarios ni aceptación en un

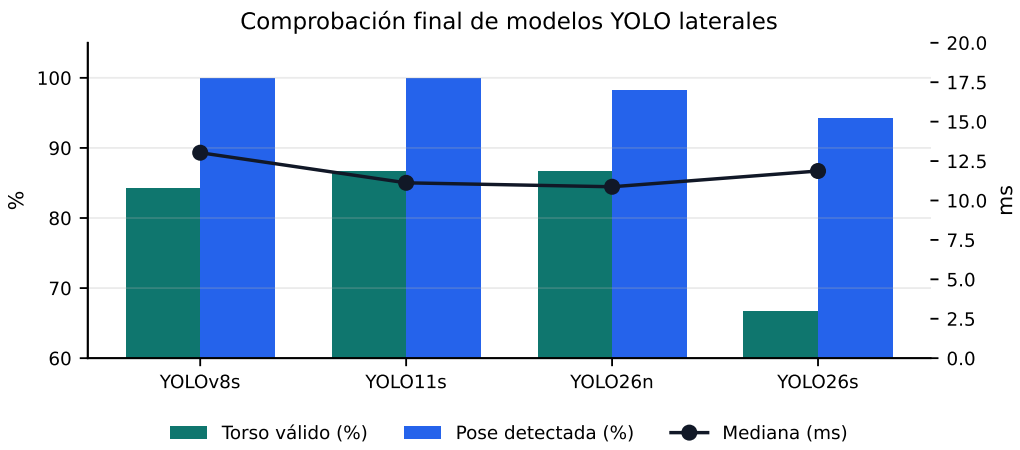

Figura 5: Comparación final de candidatos YOLO para vista lateral. *Fuente: benchmark final de modelos laterales.*

entorno de PRL real.

2 Desviaciones respecto al plan inicial

El plan inicial partía de una solución apoyada principalmente en datasets visuales y una evaluación frontal. La experimentación obligó a pivotar en cuatro aspectos:

1. **De etiquetas visuales a reglas paramétricas.** La discrepancia entre percepción humana y medición geométrica hizo necesario separar clasificación visual y diagnóstico ergonómico.
2. **Incorporación de vista lateral.** El plano frontal no era suficiente para cuello adelantado y tronco hacia delante, por lo que se añadió un pipeline específico de perfil.
3. **Uso de datos 3D para calibración.** El dataset MultiPosture se incorporó como referencia para ajustar reglas de tronco, aunque no sustituye a las imágenes reales porque no contiene evidencia visual.
4. **Evolución hacia WebApp local.** La prueba técnica acabó incluyendo backend, frontend, autenticación, histórico y depuración visual. Esta ampliación excede una simple libreta experimental, pero mejora la demostrabilidad del producto.

Estas desviaciones no se consideran fallos de planificación, sino ajustes derivados de la evidencia. La vista frontal por sí sola no podía observar suficientes variables; las etiquetas de los datasets no eran equivalentes a criterios ergonómicos; y una demo basada solo en notebooks no permitía demostrar el ciclo completo de uso. El alcance final mantiene la promesa principal del proyecto, análisis preventivo con webcam y privacidad local, pero la materializa con una arquitectura más defendible.

3 Dificultades durante la ejecución

Rigidez de las reglas frente a percepción humana. La diferencia de altura de hombros, por ejemplo, puede parecer visualmente tolerable y aun así superar umbrales geométricos. Esto explica que muchas imágenes etiquetadas como *Looks Good* terminen en `risk`. La conclusión no es que el motor falle, sino que requiere calibración y feedback cuidadoso para no saturar al usuario.

Ruido de datasets públicos. Los datasets auxiliares mezclan condiciones, encuadres y criterios de etiquetado. Por ello se usaron como material de exploración y benchmark, no como verdad final.

Oclusión por mobiliario. ROSA evalúa silla, monitor, teclado, ratón y postura de segmentos corporales [2, 3]. Sin embargo, una webcam frontal integrada no ve normalmente tren inferior, muñecas

ni apoyos de pies. La arquitectura final acepta esa limitación y evita prometer una puntuación ROSA completa.

Coste computacional y modelos ligeros. MoveNet fue rápido, pero no ofreció cobertura suficiente para perfil. YOLO Pose proporcionó mejor robustez lateral a cambio de mayor dependencia de PyTorch/Ultralytics [4]. MediaPipe quedó como opción frontal estable y ligera para la captura habitual [5].

Privacidad y almacenamiento. El tratamiento de imágenes personales obligó a una arquitectura local-first. Esta decisión redujo riesgo legal y ético, pero añadió trabajo de seguridad: cifrado local, autenticación, semillas de usuario no destructivas y eliminación de imágenes temporales.

Cierre de producto. Convertir el pipeline en una aplicación exigió resolver detalles que no aparecen en un benchmark: gestión de sesiones, límites de subida, feedback comprensible, estados de error, modo técnico de depuración, compatibilidad claro/oscuro y scripts de instalación. Este trabajo fue necesario para pasar de una prueba algorítmica a una herramienta demostrable.

4 Acciones de mejora y evolución futura

Línea de mejora	Descripción
Validación con usuarios reales	Ejecutar un piloto controlado en oficina o teletrabajo para medir precisión percibida, aceptación y reducción de alertas repetidas.
Fusión frontal-lateral	Mantener la inferencia combinada como funcionalidad inicial y validarla experimentalmente antes de presentarla como diagnóstico cerrado.
Calibración con expertos	Ampliar la calibración con datasets 3D y, si es posible, con anotaciones realizadas por especialistas en ergonomía.
Modo corporativo opcional	Añadir agregación anónima para PRL: estadísticas globales por equipo o departamento sin conservar imágenes ni identificar trabajadores.
Empaquetado nativo	Convertir los lanzadores actuales en instaladores firmados para Windows/macOS/Linux cuando se cierre el entorno objetivo.
Hardware adicional	Explorar cámaras laterales o periféricas para medir tren inferior y apoyos, siempre con consentimiento explícito.

5 Conclusiones

5.1 Conclusiones de negocio

El proyecto aborda un problema relevante: los trastornos musculoesqueléticos son una de las dolencias laborales más comunes en Europa y generan costes elevados para empresas y sistemas de salud [6]. La prevención ergonómica tiene sentido empresarial porque reduce riesgo de absentismo, molestias crónicas y pérdida de productividad.

La propuesta tiene tres ventajas de negocio:

- **Bajo coste de adopción.** Usa webcam y ordenador existentes, sin sensores externos en el MVP.
- **Privacidad por diseño.** El análisis local evita convertir la herramienta en vigilancia laboral, un punto crítico para aceptación del trabajador.
- **Feedback preventivo.** El sistema puede generar recomendaciones tempranas y registrar evolución sin esperar a una evaluación presencial puntual.

La métrica de reducir riesgo ROSA alto en un 20 % debe tratarse como hipótesis de negocio, no como resultado demostrado. Para afirmarla sería necesario un despliegue longitudinal con usuarios reales,

línea base, intervención y seguimiento.

El valor comercial más inmediato está en entornos de teletrabajo y oficinas híbridas, donde las revisiones ergonómicas presenciales son puntuales y costosas. La herramienta permitiría detectar patrones de riesgo antes de que se conviertan en lesión, manteniendo al trabajador como destinatario principal del feedback.

5.2 Conclusiones tecnológicas

La arquitectura demuestra que la visión artificial local puede integrarse en una herramienta ergonómica usable. La separación por módulos facilita evolucionar modelos, reglas y web sin reescribir todo el sistema. La especialización por vista ha sido la decisión más sólida: MediaPipe frontal para cabeza/hombros y YOLO11s lateral para perfil.

La mayor lección técnica es que un sistema de ergonomía no puede limitarse a clasificar imágenes como buenas o malas. Debe explicar qué mide, cuándo no tiene datos suficientes y qué limitaciones impone el encuadre. Esta transparencia mejora la calidad del feedback y reduce el riesgo de decisiones incorrectas.

El producto final queda como una base viable para una herramienta preventiva corporativa: no es un dispositivo médico ni una auditoría ROSA completa, pero sí una plataforma modular, privada y experimentalmente justificada para detectar señales posturales relevantes.

Referencias

[1] DTL2_GT12, “Proyecto integrador i: repositorio de código y resultados,” 2026.
[2] M. Sonne, D. L. Villalta, and D. M. Andrews, “Development and evaluation of an office ergonomic risk checklist: Rosa - rapid office strain assessment,” *Applied Ergonomics*, vol. 43, no. 1, pp. 98–108, 2012.
[3] F. C. de Barros, C. S. Moriguchi, T. C. Chaves, D. M. Andrews, M. Sonne, and T. de Oliveira Sato, “Usefulness of the rapid office strain assessment (rosa) tool in detecting differences before and after an ergonomics intervention,” *BMC Musculoskeletal Disorders*, vol. 23, no. 526, 2022.
[4] Ultralytics, “Pose estimation,” 2026.
[5] Google AI Edge, “Mediapipe pose landmarker,” 2026.
[6] European Agency for Safety and Health at Work, “Musculoskeletal disorders,” 2026.